

Self attention convolutional neural network with time series imaging based feature extraction for transmission line fault detection and classification

Self attention convolutional neural network with time series imaging based feature extraction for transmission line fault detection and classification

- Literature Review
- Contribution
- Methodology
 - System modeling with data preparation
 - Data preparation
 - Generation of signal segments
 - Time series imaging
 - Proposed SAT-CNN model for fault detection and classification
 - Proposed SAT-CNN model for fault detection and classification
 - Self-attention mechanism
- Experiments
 - Training and testing of the proposed SAT-CNN architecture
 - Performance evaluation of the proposed SAT-CNN
 - Effect of fault distance*
 - Effect of fault distance*
 - Effect of signal type and sampling frequency*
 - Enhancing system performance with noise tolerant feature extraction*
 - Comparative study with existing methods*
- Conclusion & Future work

输电线路在实际系统中不断地经历并联故障的影响，提高了系统的不稳定性、线路恢复成本和破坏了负荷。因此，为了快速恢复故障相位，需要一个鲁棒、精确的故障检测和分类（FDC：for detection and classification）模型。在本文中，我们提出了一种基于时间序列编码图像的SAT-CNN框架，用于输电线路的检测和分类(FDC)特征提取模型。

Literature Review

故障的去除可以提高供电质量，增加系统的稳定性，增强电网的暂态稳定性。虽然故障阶段的恢复目前还是取决于人，但是它可以依靠检测和分类可以预测发生了哪些故障，因为快速精确的发现故障增加了从电网中快速解决故障的机会。

为了快速和准确地识别故障，目前已经进行了大量研究。其中被证明比较有效的是利用神经网络进行故障检测，通过从原始电压和电流信号中提取底层故障特征来检测故障类型。虽然故障信息是由三相电压和电流信号带来的，但仅用原始的三相数据很难对故障进行分类。因此，就有的研究使用小波变换、克拉克变换、S变换等方法来提取故障特征。

为了对输电线路中的故障进行分类，已经发展了几种故障分类方法。其中，基于传统电路理论和现代计算智能方法的分析方法被广泛应用于识别特定类型的故障；还有人提出了一种基于对称电路元件理论的自动分析方法用于故障相的选择。除了对称分量理论外，研究人员还利用陈等人提出的基于基本电路理论的经典方法进行故障诊断任务。经典方法的优点是计算和实现都简单，但是这些方法在决策中相对较慢，因此需要设计多个有效的设备来加快决策能力，而由于传输线参数的限制，经典方法容易产生不准确的结果。

随着电力系统中复杂度的增加，故障诊断任务寻求一种用于处理大量数据的更复杂的算法。基于特征的生成，有人提出了一种基于改进的模糊逻辑（MFL）的分类器来识别有限数量的故障。在MFL中，三相电压和电流通过预处理成为样本，从而以很高的准确度对故障进行分类。但是，对于各种各样的电力系统条件，MFL分类器显示出其分类性能的变化。另外，设计基于MFL的分类器取决于专家对某些操作情况的经验。然后又有人提出了利用SVM进行故障诊断，尽管SVM对于少量数据可以令人满意地执行，但是由于目标类别重叠，因此该算法不适用于大量数据。

为了解决与上述方法相关的缺陷，论文采用神经网络的方式进行建模，由于计算机视觉算法在图像分类领域的快速发展，启发了将三相信号表示为图像的想法。将信号表示为二维图像可以使模型在视觉上对故障进行分类，以期揭示一维时间序列中未发现的高级故障特征。在此研究中，将GAF用于将时间序列三相电压和电流信号编码为图像。为了从图像中探索更深层的特征，需要具有更多区分性的人工智能算法。有鉴于此，引入了卷积神经网络（CNN），它以其深层结构学习了高级功能，并确保了更好的分类性能。还有研究表明自注意力机制SAT着眼于更占优势的图像区域以提高分类性能。因此，为提高常规CNN结构的性能，论文提出将自注意力（SAT）机制与CNN集成在一起。

除此之外，为了提高所提出的SAT-CNN模型的抗噪性能，该研究还提出了用小波变换对该模型的扩展。

Contribution

总之，论文的贡献主要有以下五点：

- 1、提出了基于卷积神经网络结合小波变换的输电线路故障检测与分类的新方法，使网络可以有效地训练和提取三相故障数据的相关特征
- 2、将自注意力机制与CNN集成在一起，更准确地识别特定类型的故障，从而使故障诊断进行更精确分类。
- 3、在各种采样频率下采用输入信号（如电压信号，电流信号以及与电压和电流信号组合）的变化来验证所提出模型的性能。
- 4、考虑输入数据的噪声，以证实所提出的SAT-CNN模型的鲁棒性。
- 5、对提议的模型和其他一些最先进的模型进行性能比较，以确认提出的SAT-CNN模型的高性能。

Methodology

System modeling with data preparation

本文考虑了一条长度为100 km的220 kV，50 Hz传输线，以对3个电力系统网络进行建模。线路电压和电流信号是从总线的源Source 1侧以20 kHz采样频率采样的。通过改变频率以观察所提出模型的性能。收集的电压和电流信号构成了分类和检测输电线路故障所需的数据。对于图1（b）所示的各种系统参数，已经模拟了十种类型的故障，以收集执行分类任务所需的数据。

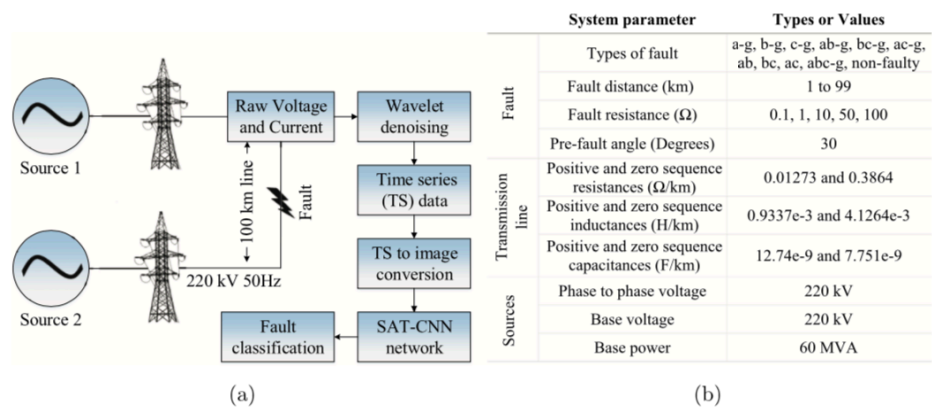


Fig. 1. (a) Block diagram of FDC system with SAT-CNN and (b) Specification of the system parameters used for the preparation of data set.

Data preparation

对于故障检测任务。论文将“非故障”也视为分类中的一类，论文采用的数据中所有的故障再加上“非故障”一共有11类故障。训练SAT-CNN模型需要从使用原始电压和电流信号生成的图像中提取特征。每个故障都有基于系统参数的特定信号类型。

Generation of signal segments

在同一时间范围内，用于训练模型的信号数据不足以获得更大的分类精度。因此，可以使用不同时间范围内的信号数据来准备所需的数据集。仿真以20 kHz的采样频率运行1.5 s。对于每个传达故障信息的三相信号，总共收集了15,000个数据点。此外，数据样本被分为7个不同的时间范围，称为时间窗口。每个时间窗口加长10,000，并从 $[j - 3000, j + 6999]$ 开始。其余时间范围表示为 $[j - 2000, j + 7999]$, $[j - 1000, j + 8999]$, $[j, j + 9999]$, $[j + 1000, j + 10999]$, $[j + 2000, j + 11999]$, $[j + 3000, j + 12,999]$ ，其中j是故障开始时的数据点。为了创建数据集，收集了32,670个模拟信号样本并将其分为7次范围。因此，生成了228,690个时间窗口，并应用了GAF来创建最终的图像数据集。混合编码的时间序列图像，并分配70%的图像进行训练，其余30%的图像进行测试。通过指示故障类型来对每个图像进行标定等级。在不同的系统参数变化和时间窗口下生成数据可以显著提高所提出模型的整体分类精度。

Time series imaging

论文提出的FDC模型使用编码的电压电流信息图像作为input。在本项研究中，电压和电流数据被表示为GAF图像。每个包含时间窗口的故障由每个三相电压和电流信号总共10,000个数据点组成。

具体GAF过程不介绍，详细可见第四周学习内容。

Proposed SAT-CNN model for fault detection and classification

Proposed SAT-CNN model for fault detection and classification

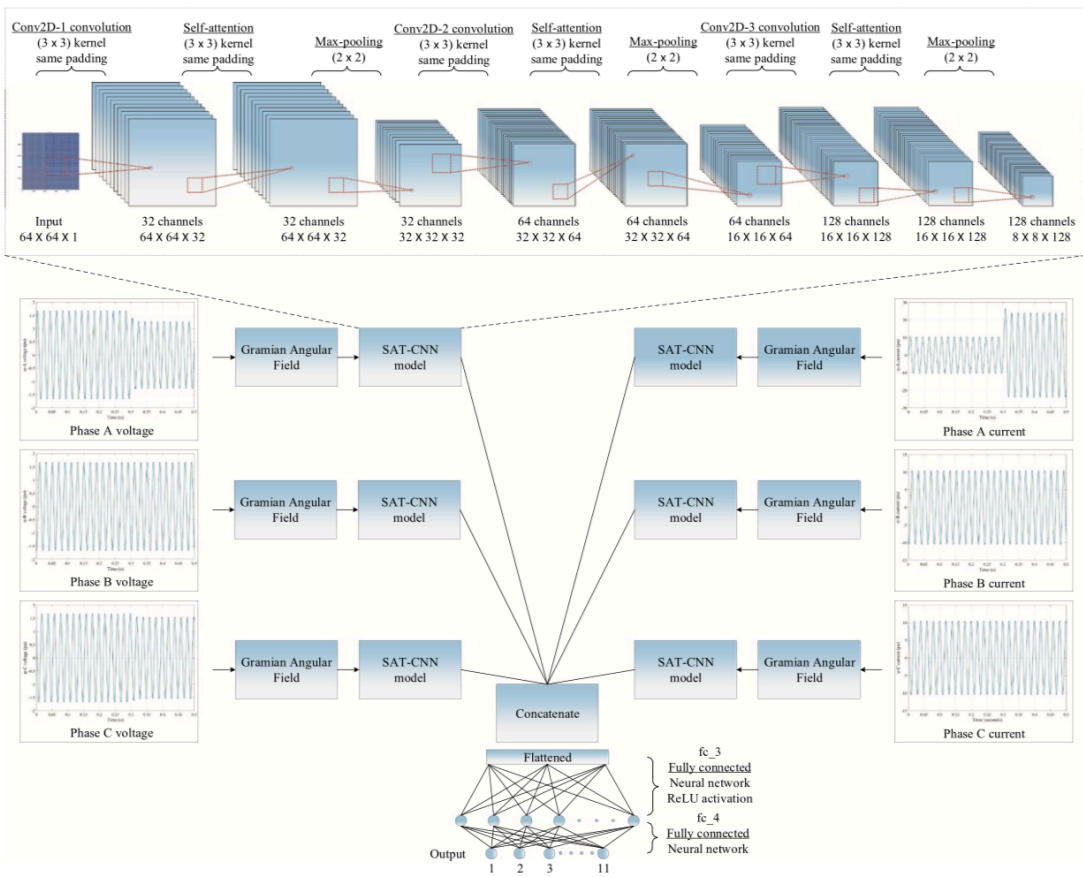


Fig. 5. Proposed SAT-CNN model architecture.

图5展现了SAT-CNN模型的结构。

整个流程开始于传输线三相信号的数据采集；接下来是把信号数据转码成GAF图像，图像被resize为 64×64 像素大小的图片；随之，来自不同相位的电压电流6个图像馈送至SAT-CNN模型中去分类传输线的故障。

SAT-CNN模型的结构通过使用卷积，自注意层和池化层的顺序操作对GAF图像进行分类。并通过可微函数将激活值从一个单元转移到另一个单元。第一层由卷积内核组成。第二层找出模型应注意的内容。所提出的结构使用空间不变性来避免所获得结果的过拟合，该结构在传统CNN体系结构和提议的CNN体系结构之间有所区别。所提出的SAT-CNN在卷积层和最大池层，过滤器，过滤器大小和节点方面的架构元素与CNN模型（如AlexNet）相似，只是在完全连接（FC）层和自我注意机制有所不同。

Self-attention mechanism

深度CNN模型在许多图像识别任务中获得了很好的性能，但在CNN的推导过程中去做决定仍然是很有挑战性的。局部接收场对特征的有效提取的狭窄程度使得卷积算子在处理广泛的输入信号时存在问题。因此，为了捕捉远程依赖关系，论文提出了一种具有自注意力机制的深度CNN体系结构。

深度CNN模型已经在许多图像识别任务中获得了有希望的性能，但是在CNN的推导过程中做出决定仍然是具有挑战性的。用于有效提取特征的局部接收场的狭窄程度，使得卷积算子在处理各种输入信号时会出现问题。因此，为捕获长范围的依赖关系，本研究提出了一种具有自我注意机制的深层CNN体系结构。从特征图获得每个卷积层的SAT图，其中将所有位置的特征的加权总和视为关注值。因此，SAT机制通过有效地建模图像区域上的远程依存关系来补充局部卷积运算。从特征映射中得到每个卷积层的SAT

图，其中所有位置的特征加权和被认为是注意力值。

注意力值的计算公式如下：

$$Y_p = \frac{1}{C(X_p)} \sum_q s(X_p, X_q) h(X_q) \quad (9)$$

此外，在注意力层实现了残差学习。因此，注意层的输出具有两个组成部分：来自先验卷积层的特征图和提供非本地信息的自注意力图。参数 β 平衡了响应中两个组件的贡献，这是在整个培训过程中学习的。 β 的初始值设置为0，并在优化时逐渐增加。SAT层的结构如图6所示。




Fig. 6. Structure of self-attention layer.

Experiments

Training and testing of the proposed SAT-CNN architecture

在不同参数变化的情况下研究了所提出的传输线FDC模型的性能。已根据以下三个因素评估了系统的准确性：（i）信号类型，即仅具有电压或电流数据并结合了这两种数据评估系统性能（ii）采样频率，即随着数据采集速率变化的系统性能和（iii）测量数据中是否存在噪声，即如果存在噪声，系统如何处理。此外，本节还对现有和拟议的故障检测与分类技术的准确性进行了比较研究，以表明拟议的SAT-CNN具有很高的分类性能。

Performance evaluation of the proposed SAT-CNN

故障分类性能衡量标准采用的是平均精确率AA：

$$AA = \frac{N_{correctclassification}}{N_{totaldata}}$$


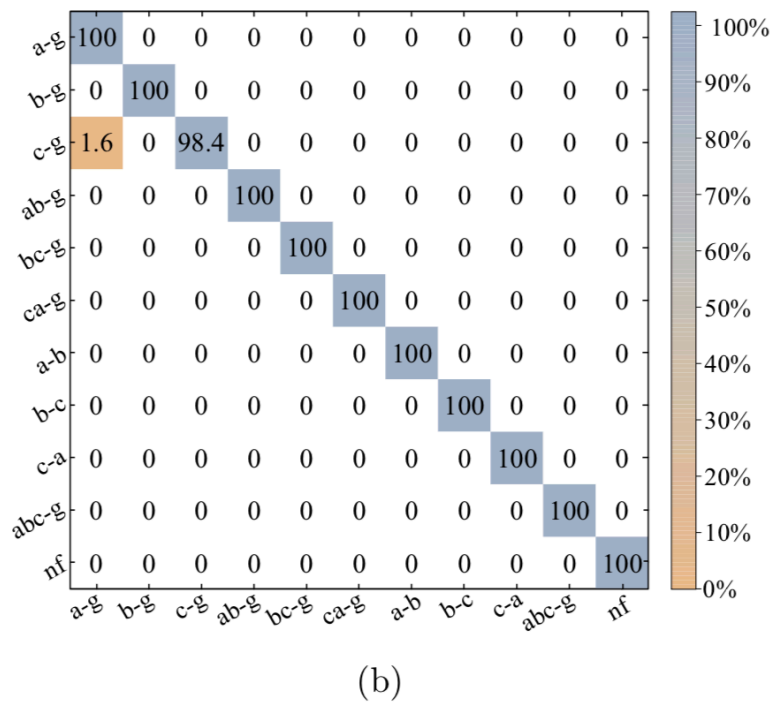


图 7展示了损失曲线和精确率曲线。它显示了模型是如何在每个阶段学习的。结果表明，60 epoch后的精确度几乎达到1，如果对模型进行次数过高或者太低的训练，会导致模型过拟合/拟合不足。可以看到，60 epoch以后，系统达到最优了，超过60epoch后，曲线就没有明显的变化了。因此，为了避免模型过拟合和欠拟合，练在60epoch后停止。

但是，仅仅AA这个指标不足以评价整个系统的性能优劣，论文还用了confusion matrix补充评价SAT-CNN的性能。



confusion matrix

每个网格的颜色深度表示正确分类的类别的百分比。混淆矩阵告诉分类器如何针对每个故障类别执行。从混淆矩阵可以看出，大多数类别均已正确分类。虽然几个“c-g”实例被错误地放置在“a-g”类别中。

Effect of fault distance

在实际中，故障可能会发生在输电线路的任何地方，因此我们要在提出的SAT-CNN中考虑故障距离带来的影响，使系统能够分析传输线任意点的信号。论文的做法主要是在数据准备上，故障位置变化超过1公里到99公里，记录相应的电压和电流信号。

例如：

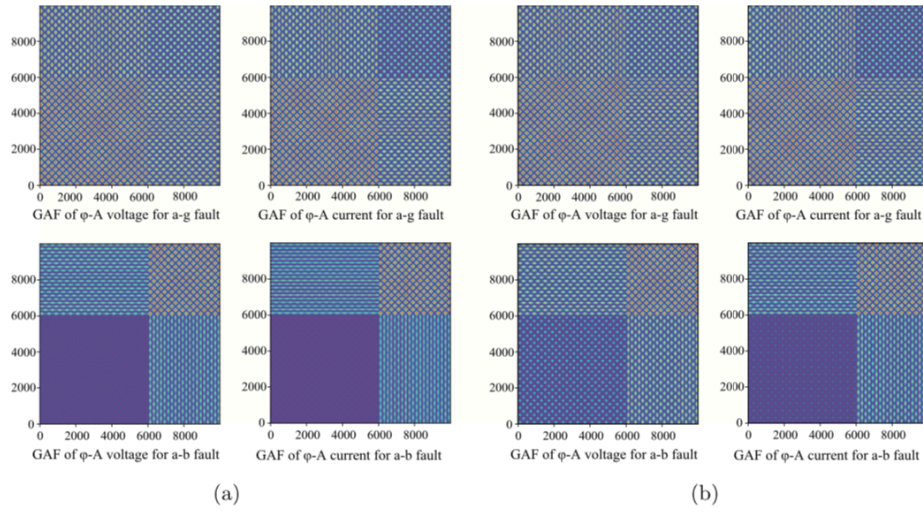


Fig. 3. GAF image of φ -A voltage and current signal during 'a-g' and 'a-b' fault at (a) 20 km; and (b) 80 km fault distance.

图三给出了模拟相A电压和电流信号在20公里和80公里距离处的gramian图像表示。

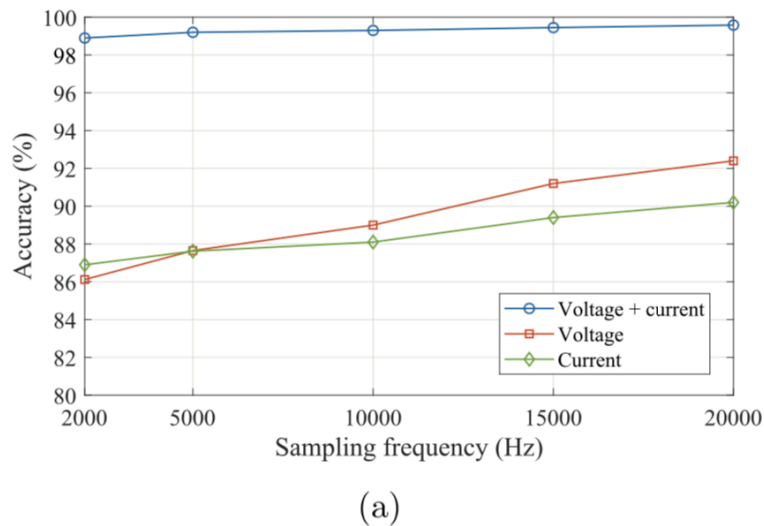
Effect of fault distance

另一个对FDC产生重大影响的系统参数是故障电阻。如果不考虑故障电阻，则接地故障可能会导致信号测量数据不正确。

Effect of signal type and sampling frequency

在提出的故障分类方案中，以20 kHz的采样频率获得三相电压和电流信号。实际上，由于设备数据采集速率的限制，最大采样频率可能低于20 kHz。在某些情况下，由于不必同时使用两个信号，因此系统仅需将电压或电流信号用于分类任务。因此，在使用相同的训练和测试数据集的情况下，可以检查提出的分类器在不同信号类型和采样频率变化下的性能。用于数据采集的采样频率为2 kHz，5 kHz，10 kHz，15 kHz和20 kHz，信号类型为三相电压或电流以及组合的电压和电流信号。通过重复5次分类过程，可以得出特定信号类型和采样频率的分类精度。然后计算分类精度的平均值，以获得总体结果。


不同信号类型和采样频率对应的分类器性能如下图所示：



从结果来看，这三种信号的分类精度都随着采样频率的增加而提高。这个趋势是符合预期的，因为较高的采样频率包含了特定故障类型的更多详细信息。但是组合的信号样本对所有采样频率执行的分类精度最高。在较低的采样频率下，系统对电流信号数据的性能由于电压信号数据的性能，但是在更高的采样频率下，通过电压信号数据可以观察到更高的分类性能。在接近5 kHz的采样频率下，各个电压和电流信号的精度大致相同。这也符合预期，因为对于特定故障类型，电流信号比电压信号包含更多的低频信息。另一方面，电压信号包括更多的故障引起的瞬变周期，其适合于揭示故障类型。根据下图中用电压信号描述的单个故障类别的准确度，FDC错过了很多正确的“c-g”和“ca-g”实例。

Table 2

Individual fault class accuracy for voltage, current and combined voltage and current data.



同样，只有电流信号的分类器在20kHz采样频率下以95%的总体精度对故障进行分类。从表2中可以看出，几乎一半的“BC-g”实例没有被正确分类。同样，在“a-g”和“b-c”类中也观察到大量的漏分类。上述分析表明，无论是电压还是电流信号，都不能达到预期的分类精度。当考虑这两种信号时，才可以在被认为是电流和电压方面的特定故障信息的频率范围内获得更高的分类精度。值得注意的是，仅对电压或电流信号的分类精度并不令人满意，而它们的组合在相当大的频率范围内提供了99%以上的精度，这证实了所提出的模型的高性能。

Enhancing system performance with noise tolerant feature extraction

实际上，三相信号还会受到自然噪声或统计不确定性的影响，这会导致分类性能下降。因此，为了使所提出的分类器能够抵御噪声，利用小波变换对信号进行降噪。

在本研究中，将附加高斯白噪声(AWGN)与模拟故障信号相加，并在小波多分辨率分析中作为输入，提取与故障电流和电压数据相关的近似和细节分量。为了演示降噪过程，分别以四级分解将a-g故障期间的噪声A相电压和电流信号施加到DWT，如图9 (a) 和 (b) 中所示。

在级别1处，我们可以看到在故障出现时时出现尖峰，这表示故障相电流和电压信号中可用的最大频率。每次在信号突然变化期间都可能会出现该尖峰。因此，信号尖峰的检测不是检测传输线故障的正确方法。小波详细系数表明信号中存在某个包含一些较小尖峰的边带会随着故障类型，故障电阻和故障距离的变化，而发生明显变化。从图中可以看出，如果执行小波分解超过第4级，则会发现信号中包含较宽的边带，这会使与故障类型，故障位置和电阻的相关性变得复杂化。因此，在这项工作中，有意义的特征是从三级系数中提取的。

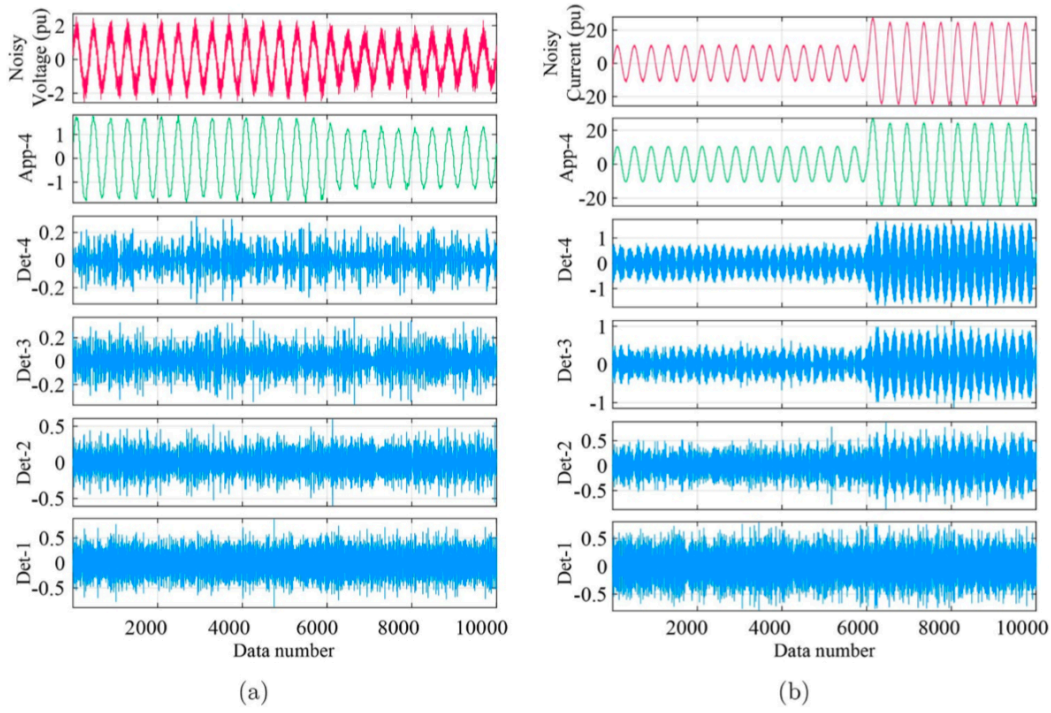
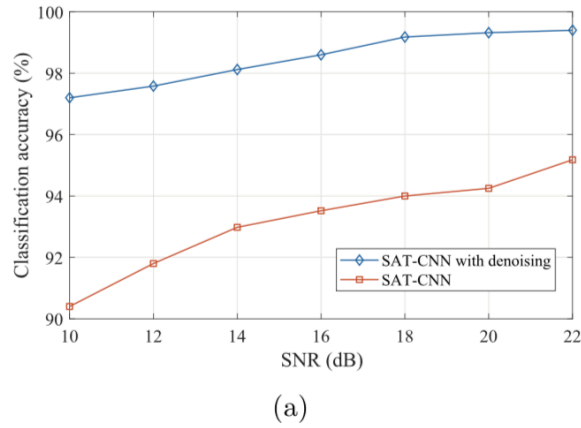


Fig. 9. Signal denoising with DWT (a) voltage signal (b) current signal.

为了验证论文提出的FD此模型可以承受信号测量中的噪声，我们使用了电压和电流信号的新数据集对系统进行了仿真。先前生成的数据集称为数据集-I，而新生成的数据集称为数据集-II。数据集-I用于训练SAT-CNN，数据集-II用于通过小波消噪器测试模型有效性。去噪模型重建原始信号，执行时间序列编码图像操作，然后根据输入图像预测故障类别，最后SAT-CNN和去噪后的SAT-CNN对分类精度的比较如图10 (a) 所示，



从性能上可以看出，去噪后的SAT-CNN模型对不同信噪比 (SNR) 值的分类精度不小于97%，符合预期。另一方面，对于SAT-CNN模型，在低信噪比的情况下，分类性能会下降。在信噪比为10 dB时，SAT-CNN分类故障的准确度为91.26%。如果信噪比增大，则表明SAT-CNN模型的分类精度会有所提高，尽管不去噪模型在不同的信噪比下的性能要比去噪SAT-CNN模型的精度低。结果表明，去噪后的SAT-CNN模型大大降低了在原始三相电压和电流信号中添加AWGN的效果，证明了所提分类器的鲁棒性。

Comparative study with existing methods

论文提出的模型与当前一些先进的方法【有噪声/无噪声】进行比较，结果显示论文提出的SAT-CNN模型的优越性。

No	Reference	Techniques used	Input signal type	Performance with noise	Average FDC accuracy
1	[23]	WPT + SVM	Current	Not mentioned	99.21%
2	[4]	WT + ELM	Current	Not mentioned	96.53%
3	[19]	Fuzzy interface	Voltage + current	Not mentioned	99.00%
4	[25]	ST + PNN	Voltage	Not mentioned	99.6%
5	[18]	MFQL	Voltage + current	Not mentioned	99.32 %
6	Proposed classifier	WT + SAT-CNN	Voltage + current	Noise immune	99.58%

(b)

Table 3
Comparison of classification performance with noise.

Method	Performance with noise (at 20 dB SNR)
[40]	99.01%
[41]]	97.45%
SAT-CNN	99.52%

Conclusion & Future work

论文提出了一种新颖的输电线路故障检测与分类方法。提出的SAT-CNN方法将三相电压和电流信号都用于检测和分类任务。为了提高系统的通用性，通过传输线参数的变化来收集信号的波形，然后使用DWT对其进行进一步分析。所提出的方法的显着优点是它可以隐式地关注来自隐藏层的输出信息，从而提高了系统的分类精度。这项研究得出的结果表明，对于所有类型的故障，该方法对故障的分类精度均接近100%。不同采样频率和所考虑的信号类型的结果说明，通过在所考虑的频率范围内利用电压和电流信号，可以实现良好的性能。通过使用测量中出现的噪声来进一步证明所提方法的性能，以证明其可承受性。

现有分类器和建议分类器之间的比较研究是根据实例数量，输入信号类型的数量和测量误差进行的。比较结果证实，提出的分类器提供了更稳定和可靠的性能。

分类器的未来实现可能会考虑仪器采集并部署在实际电网中的真实数据。